

2 图像去畸变 (3 分, 约 1 小时)

现实生活中的图像总存在畸变。原则上来说, 针孔透视相机应该将三维世界中的直线投影成直线, 但是当我们使用广角和鱼镜头时, 由于畸变的原因, 直线在图像里看起来是扭曲的。本次作业, 你将尝试如何对一张图像去畸变, 得到畸变前的图像。



图 1: 测试图像

图 1 是本次习题的测试图像 (code/test.png), 来自 EuRoC 数据集 [1]。可以明显看到实际的柱子、箱子的直线边缘在图像中被扭曲成了曲线。这就是由相机畸变造成的。根据我们在课上的介绍, 畸变前后的坐标变换为:

$$\begin{cases} x_{\text{distorted}} = x(1 + k_1r^2 + k_2r^4) + 2p_1xy + p_2(r^2 + 2x^2) \\ y_{\text{distorted}} = y(1 + k_1r^2 + k_2r^4) + p_1(r^2 + 2y^2) + 2p_2xy \end{cases} \quad (1)$$

其中 x, y 为去畸变后的坐标, $x_{\text{distorted}}, y_{\text{distorted}}$ 为去畸变前的坐标。现给定参数:

$$k_1 = -0.28340811, k_2 = 0.07395907, p_1 = 0.00019359, p_2 = 1.76187114e - 05.$$

以及相机内参

$$f_x = 458.654, f_y = 457.296, c_x = 367.215, c_y = 248.375.$$

请根据 `undistort_image.cpp` 文件中内容, 完成对该图像的去畸变操作。

注: 本题不要使用 OpenCV 自带的去畸变函数, 你需要自己理解去畸变的过程。我给你准备的程序中已经有了基本的提示。作为验证, 去畸变后图像如图 2 所示。如你所见, 直线应该是直的。



图 2: 验证图像

作业的代码部分均见附件。

`image_undistorted`

3 双目视差的使用 (2 分, 约 1 小时)

双目相机的一大好处是可以通过左右目的视差来恢复深度。课程中我们介绍了由视差计算深度的过程。本题, 你需要根据视差计算深度, 进而生成点云数据。本题的数据来自 Kitti 数据集 [2]。

Kitti 中的相机部分使用了一个双目模型。双目采集到左图和右图, 然后我们可以通过左右视图恢复出深度。经典双目恢复深度的算法有 BM(Block Matching), SGBM(Semi-Global Block Matching)[3, 4] 等, 但本题不探讨立体视觉内容 (那是一个大问题)。我们假设双目计算的视差已经给定, 请你根据双目模型, 画出图像对应的点云, 并显示到 Pangolin 中。

本题给定的左右图见 `code/left.png` 和 `code/right.png`, 视差图亦给定, 见 `code/right.png`。双目的参数如下:

$$f_x = 718.856, f_y = 718.856, c_x = 607.1928, c_y = 185.2157.$$

且双目左右间距 (即基线) 为:

$$d = 0.573 \text{ m}.$$

请根据以上参数, 计算相机数据对应的点云, 并显示到 Pangolin 中。程序请参考 `code/disparity.cpp` 文件。



图 3: 双目图像的左图、右图与视差

作为验证, 生成点云应如图 4 所示。



图 4: 双目生成点云结果

见 stereo_vision

4 矩阵运算微分 (2 分, 约 1.5 小时)

在优化中经常会遇到矩阵微分的问题。例如, 当自变量为向量 \mathbf{x} , 求标量函数 $u(\mathbf{x})$ 对 \mathbf{x} 的导数时, 即为矩阵微分。通常线性代数教材不会深入探讨此事, 这往往是矩阵论的内容。我在 ppt/目录下为你准备了一份清华研究生课的矩阵论课件 (仅矩阵微分部分)。阅读此 ppt, 回答下列问题:

设变量为 $\mathbf{x} \in \mathbb{R}^N$, 那么:

1. 矩阵 $\mathbf{A} \in \mathbb{R}^{N \times N}$, 那么 $d(\mathbf{A}\mathbf{x})/d\mathbf{x}$ 是什么?
2. 矩阵 $\mathbf{A} \in \mathbb{R}^{N \times N}$, 那么 $d(\mathbf{x}^T \mathbf{A} \mathbf{x})/d\mathbf{x}$ 是什么?
3. 证明:

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = \text{tr}(\mathbf{A} \mathbf{x} \mathbf{x}^T). \quad (2)$$

$$1. \mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^N, \quad \mathbf{A} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}, \quad \mathbf{A}\mathbf{x} = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n \end{bmatrix}$$

$$d(\mathbf{A}\mathbf{x})/d\mathbf{x} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}$$

$$2. \frac{d}{d\mathbf{x}} \mathbf{x}^T \mathbf{A} \mathbf{x} = \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix} \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} x_1 a_{11} + x_2 a_{21} + \cdots + x_n a_{n1}, \cdots, x_1 a_{1n} + x_2 a_{2n} + \cdots + x_n a_{nn} \end{bmatrix}$$

$$= x_1(x_1 a_{11} + x_2 a_{21} + \cdots + x_n a_{n1}) + x_2(x_1 a_{12} + x_2 a_{22} + \cdots + x_n a_{n2}) + \cdots + x_n(x_1 a_{1n} + \cdots + x_n a_{nn})$$

$$\frac{d(\mathbf{x}^T \mathbf{A} \mathbf{x})}{d\mathbf{x}} = \nabla_{\mathbf{x}} f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \cdots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T$$

$$= \begin{bmatrix} (a_{11}x_1 + \cdots + a_{n1}x_n) + (a_{11}x_1 + a_{22}x_2 + \cdots + a_{nn}x_n), \cdots, (a_{n1}x_1 + \cdots + a_{nn}x_n) + (a_{n1}x_1 + \cdots + a_{nn}x_n) \end{bmatrix}^T$$

$$= \mathbf{A}^T \mathbf{x} + \mathbf{A} \mathbf{x}$$

$$3. \text{ 证: } \mathbf{x}^T \mathbf{A} \mathbf{x} = \text{tr}(\mathbf{A} \mathbf{x} \mathbf{x}^T)$$

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = x_1(x_1 a_{11} + x_2 a_{21} + \cdots + x_n a_{n1}) + x_2(x_1 a_{12} + x_2 a_{22} + \cdots + x_n a_{n2}) + \cdots + x_n(x_1 a_{1n} + \cdots + x_n a_{nn})$$

$$\text{tr}(\mathbf{A} \mathbf{x} \mathbf{x}^T) = (\text{vec}(\mathbf{A}))^T \text{vec}(\mathbf{x} \mathbf{x}^T)$$

$$(\text{vec}(\mathbf{A}))^T = [a_{11}, \cdots, a_{1n}, \cdots, a_{n1}, \cdots, a_{nn}] \quad \mathbf{x} \mathbf{x}^T = \begin{bmatrix} x_1 x_1 & \cdots & x_1 x_n \\ \vdots & \ddots & \vdots \\ x_n x_1 & \cdots & x_n x_n \end{bmatrix}$$

$$\text{vec}(\mathbf{x} \mathbf{x}^T) = [x_1 x_1, \cdots, x_1 x_n, \cdots, x_n x_1, \cdots, x_n x_n]^T$$

$$(\text{vec}(\mathbf{A}))^T \text{vec}(\mathbf{x} \mathbf{x}^T) = \begin{matrix} a_{11}x_1x_1 + a_{12}x_1x_2 + \cdots + a_{1n}x_1x_n \\ + a_{21}x_2x_1 + a_{22}x_2x_2 + \cdots + a_{2n}x_2x_n \\ + \cdots \\ + a_{n1}x_nx_1 + a_{n2}x_nx_2 + \cdots + a_{nn}x_nx_n \end{matrix}$$

$$= \mathbf{x}^T \mathbf{A} \mathbf{x}$$

5 高斯牛顿法的曲线拟合实验 (3 分, 约 2 小时)

我们在课上演示了用 Ceres 和 g2o 进行曲线拟合的实验, 可以看到优化框架给我们带来了诸多便利。本题中你需要自己实现一遍高斯牛顿的迭代过程, 求解曲线的参数。我们将原题复述如下。设有曲线满足以下方程:

$$y = \exp(ax^2 + bx + c) + w. \quad (3)$$

其中 a, b, c 为曲线参数, w 为噪声。现有 N 个数据点 (x, y) , 希望通过此 N 个点来拟合 a, b, c 。实验中取 $N = 100$ 。

那么, 定义误差为 $e_i = y_i - \exp(ax_i^2 + bx_i + c)$, 于是 (a, b, c) 的最优解可通过解以下最小二乘获得:

$$\min_{a, b, c} \frac{1}{2} \sum_{i=1}^N \|y_i - \exp(ax_i^2 + bx_i + c)\|^2. \quad (4)$$

现在请你书写 Gauss-Newton 的程序以解决此问题。程序框架见 `code/gaussnewton.cpp`, 请填写程序内容以完成作业。作为验证, 按照此程序的设定, 估计得到的 a, b, c 应为:

$$a = 0.890912, \quad b = 2.1719, \quad c = 0.943629.$$

这和书中的结果是吻合的。

见 Gaussian - Newton 文件夹

6 * 批量最大似然估计 (2 分, 约 2 小时)

考虑离散时间系统:

$$\begin{aligned} x_k &= x_{k-1} + v_k + w_k, & w &\sim \mathcal{N}(0, Q) \\ y_k &= x_k + n_k, & n_k &\sim \mathcal{N}(0, R) \end{aligned}$$

这可以表达一辆沿 x 轴前进或后退的汽车。第一个公式为运动方程, v_k 为输入, w_k 为噪声; 第二个公式为观测方程, y_k 为路标点。取时间 $k = 1, \dots, 3$, 现希望根据已有的 v, y 进行状态估计。设初始状态 x_0 已知。

请根据本题题设, 推导批量 (batch) 最大似然估计。首先, 令批量状态变量为 $\mathbf{x} = [x_0, x_1, x_2, x_3]^T$, 令批量观测为 $\mathbf{z} = [v_1, v_2, v_3, y_1, y_2, y_3]^T$, 那么:

1. 可以定义矩阵 \mathbf{H} , 使得批量误差为 $\mathbf{e} = \mathbf{z} - \mathbf{H}\mathbf{x}$ 。请给出此处 \mathbf{H} 的具体形式。
2. 据上问, 最大似然估计可转换为最小二乘问题:

$$\mathbf{x}^* = \arg \min \frac{1}{2} (\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{W}^{-1} (\mathbf{z} - \mathbf{H}\mathbf{x}), \quad (5)$$

其中 \mathbf{W} 为此问题的信息矩阵, 可以从最大似然的概率定义给出。请给出此问题下 \mathbf{W} 的具体取值。

3. 假设所有噪声相互无关, 该问题存在唯一的解吗? 若有, 唯一解是什么? 若没有, 说明理由。

$$1. \quad \mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix} \quad \mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} x_1 - x_0 \\ x_2 - x_1 \\ x_3 - x_2 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} \quad \mathbf{H} = \begin{bmatrix} -1 & 1 & 0 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 0 & -1 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

$$2. \quad \mathbf{z} - \mathbf{H}\mathbf{x} = \mathbf{e} \sim \mathcal{N}(\mathbf{0}, \mathbf{W}) \quad (\text{不太清楚是不是这个意思})$$

$$3. \quad \text{存在。} \quad (\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{W}^{-1} \mathbf{z} \quad (\text{自己试着推一下和书上不太符, 希望可以讲一下 (讲评时)})$$